Université de Fianarantsoa École Nationale d'Informatique	**BIG DATA** M2: GID	Année universitaire : 2025-2026 Durée : 10 mn
Nom & Prénoms :	**NATOKANANAHARY Mahefanirina Ezra Marius**	
IM	**3882**	

Question à choix multiples

1- **Quel est le nom du paradigme de programmation développé à l'origine par Google qui prend en charge le développement d'applications pour le traitement de grands ensembles de données dans un environnement informatique distribué ?**
   - **a.** Hive
   - b. **MapReduce**
   - c. Google Cloud
   - d. Oracle

2- **Pourquoi le KPI Accuracy n'est souvent pas suffisant pour evaluer un modele ?**
   - a. Il est toujours superieur a 80%
   - **b. il ne donne pas une vision precise sur les resultats de l'algorithme sur les FP et les FN**
   - c. il est variable en fonction du probleme
   - d. Accuracy change en fonction de l'ordre des observations dans le training set.

3- **Dans un algorithme de regression, la difference entre la valeur predite et la valeur reelle s'appelle erreur residuelle. C'est cette erreur aue la fonction cout cherche a :**
   - a. Maximiser
   - b. **Minimiser**
   - c. Deriver
   - d. sommer

4- **Indiquez l'affirmation correcte.**
   - a. Hadoop est un environnement idéal pour extraire et transformer de petits volumes de données.
   - **b. Hadoop stocke les données dans HDFS et prend en charge la compression/décompression des données.**
   - c. Le framework Giraph est moins utile qu'une tâche MapReduce pour résoudre les problèmes de graphes et d'apprentissage automatique.
   - d. Aucune de ces réponses

5- **Sous quelle licence Hadoop est-il distribué ?**
   - a. Mozilla Public License
   - b. **Licence Apache 2.0**
   - c. Shareware
   - d. Commerciale

6- **Lequel des éléments suivants est produit par Hadoop ?**
   a. **Système de fichiers distribués**
   b. Service de messages Java
   c. JAX-RS
   d. Système de gestion de bases de données relationnelles
7- **Hadoop atteint la fiabilité en répliquant les données sur plusieurs hôtes et ne nécessite donc pas de stockage _____ sur les hôtes.**
   a. **RAID**
   b. ZFS
   c. Niveaux RAID standard
   d. Système d'exploitation
8- **La liste Hadoop comprend la base de données HBase, le système Apache Mahout _____ et les opérations matricielles.**
   a. **Machine learning**
   b. Intelligence artificielle
   c. Classification statistique
   d. Reconnaissance des formes
9- **_____ est une plateforme permettant de construire des flux de données pour le traitement et l'analyse de grands ensembles de données par extraction, transformation et chargement (ETL).**
   a. **Pig**
   b. Hadoop
   c. Hive
   d. Oozie
10- **Indiquez l'affirmation correcte:**
   a. **Hive n'est pas une base de données relationnelle, mais un moteur de requête qui prend en charge les parties du langage SQL spécifiques à l'interrogation des données.**
   b. Hive est une base de données relationnelle avec support SQL
   c. Pig est une base de données relationnelle avec un support SQL
   d. Toutes les réponses sont vraies
11- **Quel moteur exécute par défaut les requêtes Hive si aucun moteur n'est spécifié ?**
   a. Spark
   b. **Tez**
   c. MapReduce
   d. Presto
12- **Quel type de compression est splittable (donc adapté à Hadoop) ?**
   a. Gzip
   b. Zip
   c. **Bzip2**
   d. Snappy
13- **Quelle API Hadoop est utilisée pour interagir avec HDFS en Java ?**
   a. java.io.File
   b. org.hadoop.fs.HDFSTools
   c. **org.apache.hadoop.fs.FileSystem**
   d. org.apache.hadoop.hdfs.client.HDFSClient
14- **En MapReduce, que contient le fichier _SUCCESS ?**
   a. Les résultats du Reducer
   b. L'historique du job
   c. **Une preuve que le job s'est terminé sans erreur**
   d. Un résumé des statistiques du Mapper
15- **Quelle est la taille par défaut d'un bloc HDFS dans Hadoop 3.x ?**
   a. 64 Mo
   b. **128 Mo**
   c. 256 Mo
   d. 512 Mo

16- **En MapReduce, comment appelle-t-on les fichiers intermédiaires entre les phases Map et Reduce ?**
    a. Fichiers split
    b. Fichiers sortants
    c. Fichiers de post-traitement
    d. **Fichiers intermédiaires triés (spill files)**
17- **Dans YARN, un container est _____**
    a. Un conteneur Docker isolé
    b. Une instance de HDFS
    c. Une partition de cluster
    d. **Une unité de ressources (mémoire + CPU) pour exécuter des tâches**

18- **Dans Hive, quel type de table supprime aussi les fichiers HDFS quand on la droppe ?**
    a. LOGICAL
    b. EXTERNAL
    c. TEMPORARY
    d. **MANAGED (ou INTERNAL)**
19- **En Spark, que fait la méthode .collect() sur un RDD ou un DataFrame ?**
    a. Sauvegarde les données sur HDFS
    b. Compresse les résultats
    c. Distribue les données aux workers
    d. **Envoie toutes les données vers le driver**
20- **En Hive, que fait la commande MSCK REPAIR TABLE ?**
    a. Vide les partitions
    b. Répare les données corrompues
    c. Redémarre le moteur d'exécution
    d. **Ajoute au métastore les partitions HDFS manquantes**